Caracterização de Comunidades Públicas do Discord: Uma Análise de Dados sobre Conteúdo e Padrões de Interação

Rafael Corgozinho[1], **Gabriel Luiz**[1]
Gabriel Bramantes[1], **Iago Falcão**[1], **Rafael Resende**[1]

[1] Universidade Federal de Viçosa – Campus Florestal
Florestal – Minas Gerais – Brasil

Abstract. *The growing presence of digital communities has made online communication platforms relevant environments for studying social interactions and information circulation. This work proposes an exploratory analysis of public Discord servers using techniques from Data Science, Data Mining and Complex Network Analysis. The dataset comprises approximately 15.9 million messages distributed across 100 servers, collected from communities identified through the Disboard platform. The research aims to characterize the structure of these communities, investigate the topics discussed and identify patterns of user participation and interaction. At the current stage, efforts are focused on data organization, integrity assessment and the definition of preprocessing strategies. The study seeks to establish a foundation for subsequent analyses of content and interaction dynamics in public digital communities.*

Resumo. *A presença crescente de comunidades digitais tornou as plataformas de comunicação ambientes relevantes para o estudo de interações sociais e circulação de conteúdo. Este trabalho propõe uma análise exploratória de servidores públicos do Discord utilizando técnicas de Ciência de Dados, Mineração de Dados e Análise de Redes Complexas. O conjunto de dados reúne aproximadamente 15,9 milhões de mensagens distribuídas em 100 servidores, identificados por meio da plataforma Disboard. A pesquisa busca caracterizar a estrutura dessas comunidades, investigar os temas discutidos e identificar padrões de participação e interação entre usuários. Na etapa atual, os esforços estão concentrados na organização dos dados, avaliação de sua integridade e definição de estratégias de pré-processamento. O estudo pretende estabelecer uma base para análises posteriores sobre conteúdo e dinâmicas de interação em comunidades digitais públicas.*

Palavras-chave: Ciência de Dados, Discord, Mineração de Dados, Comunidades Digitais, Análise de Redes.

1. Introdução

As plataformas digitais de comunicação desempenham um papel importante na formação e na manutenção de comunidades virtuais. Por meio desses ambientes, usuários podem compartilhar informações, discutir assuntos de interesse comum e estabelecer relações sociais que se desenvolvem ao longo do tempo. Nesse contexto, compreender como essas comunidades se organizam e como seus participantes interagem é um problema que pode ser investigado por meio de técnicas computacionais.

Entre essas plataformas, o Discord apresenta características particulares de organização. Seu funcionamento é baseado em servidores, que podem conter diferentes canais de comunicação, permitindo que grupos de usuários organizem conversas em torno de assuntos variados. Essa estrutura oferece um ambiente propício para investigar não apenas o conteúdo das mensagens, mas também os padrões de participação e as relações estabelecidas entre os membros de uma comunidade.

Este trabalho propõe investigar comunidades públicas do Discord a partir de técnicas de Ciência de Dados, Mineração de Dados e Análise de Redes Complexas. A pesquisa parte de um conjunto extenso de mensagens obtidas de diferentes servidores, buscando compreender os assuntos discutidos, a distribuição da participação dos usuários e as características das interações presentes nesses ambientes.

A identificação dos servidores foi realizada a partir do Disboard, uma plataforma voltada à divulgação e descoberta de servidores do Discord. A base utilizada foi coletada por Marcus Vinicius Guerra, doutorando da Universidade Federal de Viçosa (UFV), e posteriormente disponibilizada para o desenvolvimento deste estudo. Os servidores foram identificados considerando suas tags de classificação, que abrangem categorias distintas, desde jogos e entretenimento até comunidades relacionadas a determinados movimentos e interesses.

É importante destacar que as tags utilizadas na plataforma representam categorias declaradas para identificação dos servidores, não constituindo, isoladamente, evidência de que todas as mensagens ou participantes apresentem as características associadas a essas classificações.

A partir desse conjunto de dados, pretende-se investigar questões como: quais temas aparecem com maior frequência nas comunidades analisadas? Como a participação dos usuários se distribui entre os servidores e canais? Existem padrões de interação que indiquem a formação de grupos menores dentro dessas comunidades? De que maneira os conteúdos são compartilhados e relacionados entre os participantes?

Como etapa inicial, o trabalho concentra-se na organização e na validação do conjunto de dados, considerando seu volume e sua estrutura. A partir dessa preparação, serão definidas estratégias de processamento e análise que permitam explorar as questões propostas.

2. Trabalhos Relacionados

O estudo de comunidades digitais relaciona-se com diferentes áreas da Computação, especialmente Mineração de Dados, Processamento de Linguagem Natural e Análise de Redes Complexas. Essas áreas oferecem métodos para investigar tanto o conteúdo produzido em ambientes digitais quanto as relações estabelecidas entre seus participantes.

Pesquisas sobre comunidades em plataformas como Reddit e YouTube podem contribuir para a compreensão de fenômenos relacionados à organização de grupos, à circulação de conteúdo e à construção de discursos em ambientes virtuais. Estudos que investigam comunidades temáticas também oferecem referências metodológicas para a identificação de assuntos recorrentes e de padrões de participação.

No contexto deste projeto, o interesse está em explorar uma base composta por mensagens de servidores públicos do Discord. A organização da plataforma em servidores

e canais permite observar diferentes níveis de estruturação das comunidades, enquanto os registros de mensagens possibilitam investigar a atividade dos usuários e os conteúdos produzidos.

A aproximação com trabalhos anteriores deverá considerar principalmente três dimensões: análise de conteúdo textual, investigação de interações em comunidades digitais e aplicação de redes complexas ao estudo de grupos sociais.

3. Conjunto de Dados

3.1. Origem, unidade de análise e coleta

O conjunto de dados utilizado neste trabalho é composto por mensagens provenientes de servidores públicos do Discord, plataforma de comunicação digital organizada em comunidades denominadas servidores, que podem conter diferentes canais de interação entre usuários.

A identificação dos servidores foi realizada por meio do Disboard, plataforma destinada à divulgação e descoberta de comunidades do Discord. A seleção considerou as tags utilizadas pelos próprios servidores para descrever suas principais temáticas e interesses.

A coleta dos dados foi realizada por Marcus Vinicius Guerra, doutorando da Universidade Federal de Viçosa (UFV), que disponibilizou o conjunto de dados para o desenvolvimento desta pesquisa. A partir dessa base, a equipe realizou as etapas de organização, validação, tratamento e análise exploratória dos registros.

Entre as classificações identificadas estão categorias como *amizade*, *jogos*, *resenha*, *shitpost*, *panela*, *redpill*, *blackpill*, *looksmaxxed*, *humor negro* e *nofap*, entre outras.

A Figura 1 apresenta uma representação visual dessas classificações. A diversidade de tags permite observar que o conjunto de dados abrange comunidades com diferentes interesses, não estando restrito a uma única temática. Entretanto, essas classificações são definidas pelos próprios servidores e não representam necessariamente o conteúdo de todas as mensagens publicadas.



Figura 1. Representação visual das tags utilizadas na identificação dos servidores no Disboard. A imagem ilustra a diversidade de categorias, sem representar a frequência dos termos nas mensagens.

A unidade básica de análise adotada neste estudo é a mensagem. Cada registro está associado a informações sobre seu conteúdo, autor, servidor, canal e instante de publicação. Essa organização permite investigar características textuais, padrões temporais de atividade e diferenças de participação entre as comunidades analisadas.

3.2. Caracterização da base original

A base original reúne aproximadamente 15,9 milhões de mensagens distribuídas em 100 servidores públicos do Discord. Os registros estão organizados em arquivos no formato Parquet, que utiliza armazenamento colunar e permite trabalhar com grandes volumes de dados de maneira estruturada.

Foi realizada a inspeção das estruturas dos arquivos, considerando a quantidade de colunas, seus nomes e seus respectivos tipos de dados. A Tabela 1 apresenta as principais características identificadas.

Tabela 1. Caracterização da base original.

Característica	Quantidade
Mensagens	15.886.553
Servidores	100
Arquivos Parquet	2.051
Colunas identificadas	23
Esquemas de tipos observados	1.409

As colunas disponíveis contemplam diferentes categorias de informações. A Tabela 2 especifica a organização dos atributos por grupos.

Tabela 2. Organização geral das colunas

Grupo	Colunas	Representação
Identificação	`id`, `guild_id`, `channel_id`	Identificadores da mensagem, servidor e canal.
Conteúdo	`content`, `type`	Texto e tipo da mensagem.
Tempo	`timestamp`, `edited_timestamp`	Data e hora de envio e eventual edição.
Autor	`author.id`, `author.username`, `author.global_name`, `author.avatar`, `author.discriminator`, `author.public_flags`, `author.flags`	Identificação do autor e atributos associados à conta.
Interações	`mentions`, `mention_roles`, `mention_everyone`	Menções a usuários, cargos e menções gerais.
Mídia e componentes	`attachments`, `embeds`, `components`	Anexos, conteúdos incorporados e componentes.
Outros metadados	`flags`, `pinned`, `tts`	Sinalizadores, mensagens fixadas e uso de texto para fala.

Essas informações oferecem diferentes possibilidades de investigação. Os identificadores permitem organizar os registros por comunidade, enquanto os dados temporais possibilitam observar períodos de maior atividade. Já o conteúdo textual constitui a principal fonte de informação para as futuras análises de mineração de texto.

3.3. Validação e análise de integridade

Após a caracterização inicial, realizamos uma verificação da qualidade dos dados com o objetivo de identificar possíveis inconsistências que pudessem comprometer as análises posteriores.

Essa etapa utilizou Python e a biblioteca `PyArrow` para leitura dos arquivos Parquet, além de operações tabulares para examinar a estrutura dos registros.

Entre os aspectos investigados estavam a padronização das colunas, a presença de valores ausentes e a existência de mensagens duplicadas.

A verificação dos identificadores encontrou 15.886.553 valores distintos na coluna `id`, correspondentes ao total de registros da base original. Dessa forma, não foram identificadas duplicações de identificadores nessa etapa.

Em relação aos valores ausentes, alguns atributos apresentaram percentuais elevados de informações não preenchidas, conforme a Tabela 3.

Tabela 3. Principais valores ausentes na base original.

Coluna	Ausentes	Percentual
`edited_timestamp`	15.653.076	98,53%
`author.global_name`	5.761.001	36,26%
`author.avatar`	1.607.022	10,12%

A elevada quantidade de valores ausentes em `edited_timestamp` é compatível com o funcionamento da plataforma, uma vez que mensagens não editadas podem não apresentar informações nesse campo.

De maneira semelhante, atributos relacionados ao perfil dos usuários, como nome de exibição e imagem de perfil, podem estar indisponíveis em determinados registros.

Essas ausências não comprometem diretamente as análises propostas nesta etapa, pois os principais atributos utilizados estão relacionados ao conteúdo, à identificação das mensagens e aos registros temporais.

Além da avaliação de integridade, realizamos uma caracterização inicial dos tipos de mensagens presentes na base. Para isso, examinamos os 100 primeiros arquivos Parquet, que reuniram 47.771 mensagens. O objetivo foi compreender a composição desses registros e identificar características relevantes para o tratamento dos dados nas próximas etapas da pesquisa.

A Tabela 4 apresenta a distribuição dos tipos de mensagens observados nessa análise.

Tabela 4. Distribuição dos tipos de mensagens nos 100 arquivos analisados.

Tipo de mensagem	Quantidade	Percentual
Convencional (`type=0`)	35.949	75,25%
Resposta (`type=19`)	10.567	22,12%
Registro do tipo 20 (`type=20`)	1.205	2,52%
Outros tipos	50	0,10%
Total	**47.771**	**100%**

Observa-se que a maior parte da amostra é formada por mensagens convencionais (75,25%), seguidas pelas respostas a outras mensagens (22,12%). Essa distinção é importante porque o conjunto não contém apenas publicações textuais isoladas, mas também registros associados a diferentes formas de comunicação na plataforma.

Também investigamos a presença de anexos e a disponibilidade de texto nas mensagens. A Tabela 5 resume esses resultados, considerando o preenchimento do campo `content`.

Tabela 5. Presença de anexos e texto na amostra analisada.

Característica	Mensagens	Percentual da amostra
Sem anexos	45.826	95,93%
Com anexos e com texto	423	0,89%
Com anexos e sem texto	1.522	3,19%
Total	**47.771**	**100%**

Ao todo, 1.945 mensagens (4,07% da amostra) continham anexos. Desse grupo, 1.522 (78,25% das mensagens com anexos) não apresentavam conteúdo no campo textual. Isso indica que parte dos registros não oferece texto diretamente disponível para análise, embora possa conter informações em arquivos anexados.

Essa característica deverá ser considerada na etapa de Processamento de Linguagem Natural (PLN), especialmente na preparação das mensagens para identificação de tópicos. Registros sem texto no campo `content` poderão exigir critérios específicos de tratamento, dependendo dos objetivos da análise.

Por fim, é importante destacar que a amostra foi formada pelos 100 primeiros arquivos disponíveis, sem seleção aleatória. Assim, as proporções apresentadas descrevem somente os registros examinados e não devem ser generalizadas automaticamente para as 15.886.553 mensagens da base original.

3.4. Pré-processamento e seleção de atributos

Com a conclusão das primeiras verificações, iniciamos a preparação dos dados para as análises exploratórias.

Essa etapa teve como objetivo organizar o conjunto de mensagens, selecionar os atributos mais relevantes e reduzir informações que não contribuiriam diretamente para os objetivos da pesquisa.

Uma das principais preocupações foi a presença de canais administrativos e de registros associados a atividades automatizadas, que poderiam influenciar a interpretação dos padrões de comunicação.

Para isso, foi realizada uma revisão dos canais, considerando seus nomes, suas características e seus volumes de mensagens.

Na etapa documentada de filtragem, a remoção foi concentrada em canais administrativos ou associados a bots que possuíam menos de 10 mil mensagens.

Canais com volumes superiores foram preservados para avaliações posteriores, mesmo quando apresentavam características de automação.

Essa estratégia buscou evitar a exclusão precipitada de grandes quantidades de registros. Entretanto, não garante a remoção de todas as mensagens produzidas por bots, sendo essa uma limitação considerada nas análises.

Paralelamente ao tratamento dos registros, realizamos uma seleção de atributos para facilitar o processamento e manter as informações necessárias às análises exploratórias. A base original apresentava 23 colunas, enquanto a representação utilizada na análise

exploratória de dados (EDA) passou a reunir 17 atributos, distribuídos em seis grupos, conforme a Tabela 6.

Tabela 6. Distribuição dos 17 atributos utilizados na análise exploratória.

Grupo	Atributos	Qtd.
Identificação	`id`, `guild_id`, `channel_id`	3
Conteúdo	`content`, `type`	2
Tempo e edição	`timestamp`, `foi_editada`	2
Autor	`author_id`, `author_username`, `author_nome_exibicao`, `eh_bot`	4
Interações e destaque	`mention_everyone`, `n_mencoes`, `pinned`	3
Mídias e anexos	`n_attachments`, `n_embeds`, `tem_midia`	3
Total		**17**

A seleção preservou os identificadores de mensagens, servidores e canais, o conteúdo textual e as informações temporais, fundamentais para comparar a atividade das comunidades. Também foram mantidas informações sobre autoria, menções e presença de mídias, importantes para caracterizar os registros sem precisar carregar todos os metadados originais.

Alguns campos foram renomeados ou resumidos em atributos derivados. Por exemplo, `author.id`, `author.username` e `author.global_name` passaram a ser representados por `author_id`, `author_username` e `author_nome_exibicao`.

Por outro lado, deixaram de integrar a representação analítica os campos `author.avatar`, `author.discriminator`, `author.public_flags`, `author.flags`, `mention_roles`, `components`, `flags` e `tts`, por não serem prioritários para os objetivos desta etapa. Os valores detalhados de `edited_timestamp`, `mentions`, `attachments` e `embeds` também não foram mantidos como colunas originais na exportação, pois suas informações de interesse passaram a ser representadas por campos resumidos.

Essa redução diz respeito à estrutura utilizada nas análises exploratórias; não significa, necessariamente, a exclusão definitiva dessas informações dos arquivos Parquet originais. Assim, foi possível trabalhar com uma base mais objetiva, preservando os atributos necessários às análises estatísticas, temporais e às próximas etapas de mineração de texto.

Durante a preparação, o DuckDB foi utilizado como mecanismo de consulta sobre os arquivos Parquet, permitindo organizar os registros por servidor e canal e aplicar os critérios de filtragem descritos anteriormente. O resultado desse processo foi exportado em um arquivo CSV consolidado, que constitui o conjunto de dados utilizado em todas as análises exploratórias apresentadas neste artigo.

A Tabela 7 compara as dimensões da base original com as da base consolidada.

Tabela 7. Dimensões da base original e da base consolidada.

Versão	Mensagens	Servidores
Base original (Parquet)	15.886.553	100
Base consolidada (CSV)	13.455.755	100

A base consolidada reúne 13.455.755 mensagens distribuídas em 100 servidores e 1.773 canais, o que corresponde a cerca de 84,7% das mensagens da base original. Essa redução decorre das etapas de filtragem descritas nesta seção. Por esse motivo, as análises das próximas seções utilizam como referência a base consolidada em CSV.

3.5. Limitações e considerações éticas

Embora o conjunto de dados apresente um volume expressivo de mensagens, algumas características precisam ser consideradas na interpretação dos resultados.

Inicialmente, a identificação dos servidores por meio do Disboard não representa uma seleção aleatória de todas as comunidades existentes no Discord.

Dessa forma, os resultados refletem as características dos servidores presentes na base e não podem ser generalizados automaticamente para toda a plataforma.

Outro aspecto importante está relacionado à distribuição das mensagens entre servidores, uma vez que comunidades com diferentes níveis de atividade podem apresentar quantidades muito distintas de registros.

Também é necessário considerar a possibilidade de mensagens automatizadas permanecerem na base, mesmo após os procedimentos de filtragem realizados.

Além disso, diferenças na disponibilidade histórica dos registros podem influenciar as análises temporais e as comparações entre comunidades.

Em relação aos aspectos éticos, embora os dados sejam provenientes de servidores públicos, as mensagens podem conter informações pessoais e conteúdos sensíveis.

Por esse motivo, os resultados apresentados neste artigo priorizam informações agregadas, como contagens, distribuições e estatísticas descritivas, evitando a exposição direta de mensagens e a identificação individual dos participantes.

Para as próximas etapas, especialmente aquelas relacionadas ao Processamento de Linguagem Natural (PLN), será necessário considerar medidas adicionais de proteção, como a remoção de informações pessoais desnecessárias e a limitação do acesso aos registros originais.

Esses cuidados são importantes para que a análise das comunidades seja conduzida de forma responsável, respeitando a privacidade dos participantes e as restrições aplicáveis ao uso dos dados.

4. Resultados

4.1. Caracterização de servidores e canais

Após as etapas de preparação dos dados, realizamos a análise exploratória da base consolidada, composta por 13.455.755 mensagens distribuídas em 100 servidores e 1.773 canais.

Inicialmente, buscamos compreender como essas mensagens estão distribuídas entre as comunidades analisadas.

Observamos uma diferença expressiva no volume de atividade entre os servidores. Enquanto a média é de aproximadamente 134.558 mensagens por servidor, a mediana é de apenas 5.869,5 mensagens. Essa diferença indica que alguns servidores muito movimentados elevam a média, enquanto boa parte das comunidades apresenta volumes menores.

A concentração também pode ser observada entre os servidores com maior atividade: o mais movimentado reúne 3.543.762 mensagens, o equivalente a 26,3% da base. Juntos, os cinco servidores com mais registros concentram 67,7% das mensagens, percentual que chega a 81,3% quando considerados os dez primeiros. A Tabela 8 resume esses resultados.

Tabela 8. Distribuição e concentração das mensagens por servidor.

Indicador	Resultado
Total de servidores	100
Média de mensagens por servidor	134.557,6
Mediana de mensagens por servidor	5.869,5
Mensagens no maior servidor	3.543.762
Participação do maior servidor	26,3%
Participação dos cinco maiores	67,7%
Participação dos dez maiores	81,3%

A Figura 2 complementa a tabela ao mostrar quanto do total de mensagens é acumulado à medida que os servidores são organizados do mais ativo para o menos ativo.

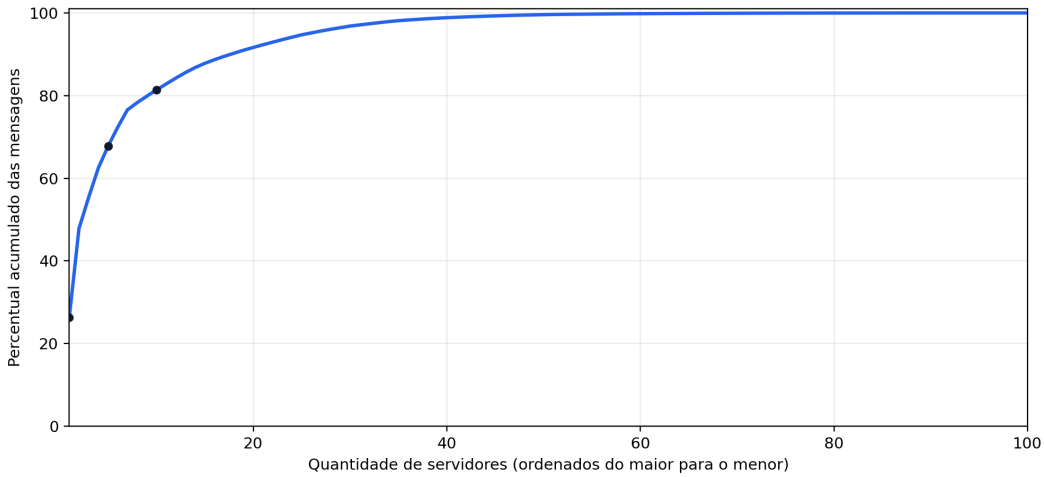


Figura 2. Participação acumulada das mensagens por servidor, em ordem decrescente de atividade.

Esses resultados mostram que a atividade registrada não se distribui de forma equilibrada entre as comunidades. Por isso, uma estatística calculada sobre todas as

mensagens pode refletir principalmente o comportamento dos servidores maiores. Nas próximas comparações, será importante analisar também os resultados de cada servidor separadamente, evitando generalizações sobre as comunidades menores.

Embora a concentração seja evidente, ela não permite, por si só, identificar uma distribuição estatística específica para o tamanho dos servidores. Essa investigação exigiria análises adicionais.

4.2. Dinâmica temporal das mensagens

Em seguida, investigamos como a atividade das comunidades se distribui ao longo do tempo. Para isso, utilizamos os registros de data e hora presentes na coluna `timestamp`, agrupando as mensagens por mês, dia da semana e hora do dia.

Os registros mensais da exportação abrangem o período de março de 2020 a agosto de 2026. O maior volume mensal foi identificado em julho de 2026, com 1.140.034 mensagens e 5.805 usuários distintos ativos naquele mês. É importante observar que agosto de 2026 contém apenas parte dos registros do mês, de modo que seu total não pode ser comparado diretamente ao de meses completos.

A Figura 3 apresenta a evolução mensal do número de mensagens ao longo do período analisado.

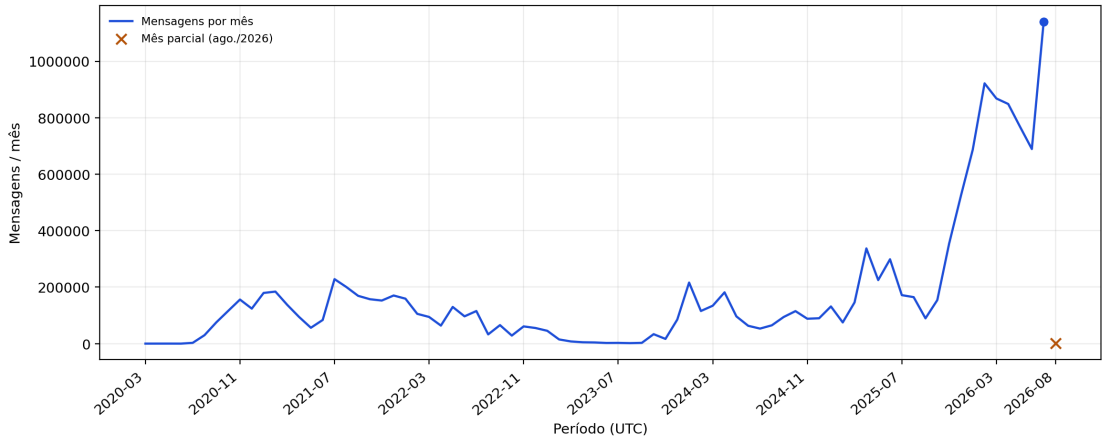


Figura 3. Evolução mensal do volume de mensagens na base consolidada. Agosto de 2026 corresponde a um mês parcial.

O gráfico mostra variações no volume de mensagens ao longo dos anos, com maior intensidade de registros em determinados períodos. Entretanto, essas oscilações não devem ser atribuídas apenas a mudanças no interesse ou na participação dos usuários. Como os servidores possuem históricos e períodos de coleta diferentes, parte das variações pode estar relacionada à quantidade de comunidades representadas em cada mês.

Também analisamos a distribuição da atividade ao longo dos dias da semana e das horas do dia. A Figura 4 apresenta um mapa de calor que permite identificar visualmente os períodos com maior e menor número de mensagens.

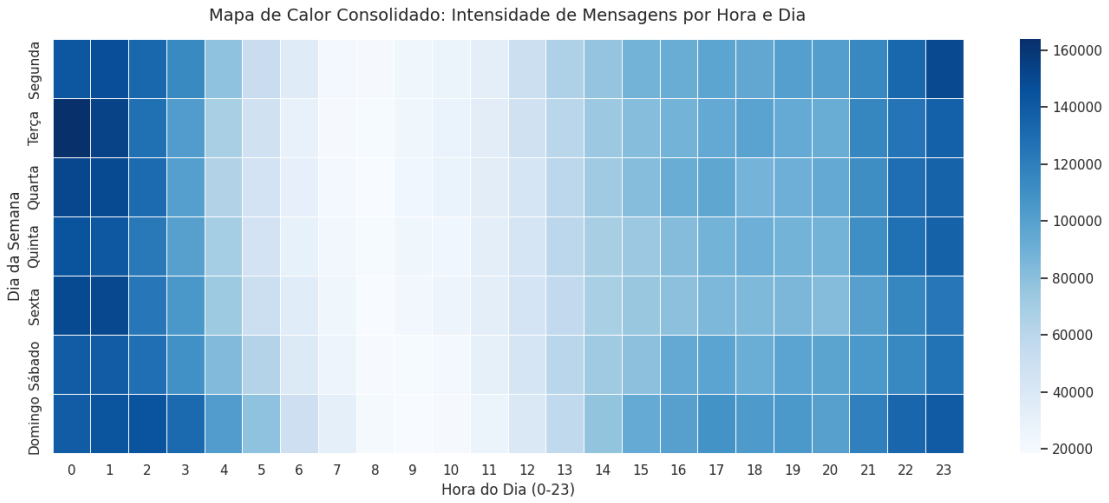


Figura 4. Distribuição das mensagens por dia da semana e hora do dia, considerando os registros temporais em UTC.

Para complementar essa visualização, a Figura 5 apresenta o volume de mensagens agrupado apenas pela hora do dia.

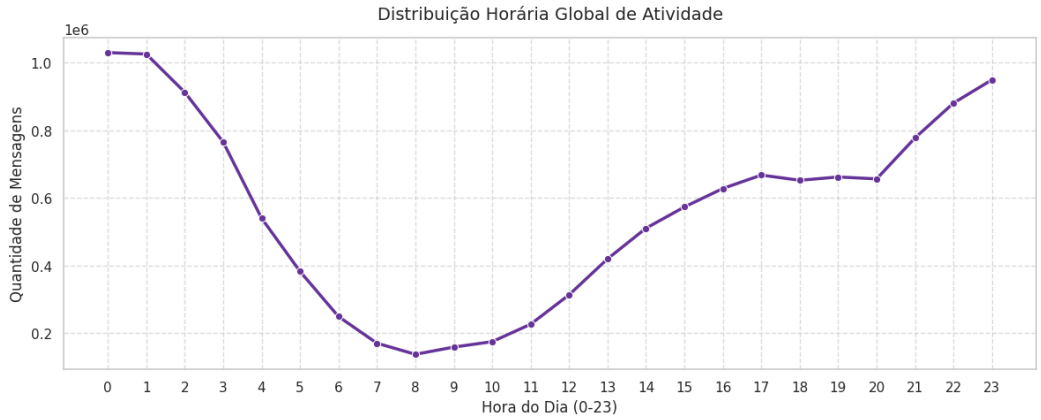


Figura 5. Distribuição do volume de mensagens por hora do dia, com horários em UTC.

Nas duas visualizações, observamos maior concentração de atividade nas horas próximas à transição entre o fim e o início do dia, considerando o horário UTC. Em contrapartida, algumas horas da manhã apresentam menor volume relativo de mensagens nesse mesmo fuso.

Esses resultados permitem reconhecer padrões de atividade na base analisada, mas não descrevem, necessariamente, a rotina local dos participantes. Os servidores podem reunir usuários de diferentes regiões e fusos horários, além de apresentar volumes de mensagens bastante distintos.

4.3. Estatísticas descritivas do conteúdo

Além do volume e da distribuição temporal, investigamos algumas características do conteúdo das mensagens. Nessa etapa, foram consideradas medidas como quantidade de

mensagens com e sem texto, comprimento das publicações, média de palavras e presença de URLs, emojis e anexos.

Das 13.455.755 mensagens da base consolidada, 11.341.061 apresentam conteúdo textual não vazio, enquanto 2.114.694 não possuem texto no campo `content`. Isso significa que aproximadamente 15,7% dos registros não contêm texto disponível para análise. Essa classificação não indica, necessariamente, que todas essas mensagens possuem imagens ou anexos: ela considera apenas o preenchimento do campo textual.

A Tabela 9 apresenta as principais estatísticas descritivas obtidas nessa etapa.

Tabela 9. Características do conteúdo das mensagens na base consolidada.

Métrica	Resultado
Total de mensagens	13.455.755
Mensagens com texto	11.341.061
Mensagens sem texto	2.114.694
Comprimento médio (caracteres)	16,57
Mediana do comprimento (caracteres)	9
Desvio-padrão do comprimento	44,16
Média de palavras por mensagem	2,97
Mensagens com URL detectada	105.109
Mensagens com emoji detectado	368.525
Mensagens apenas com emoji	171.973
Mensagens com pelo menos um anexo	192.616

A média de 16,57 caracteres por mensagem e a mediana de nove caracteres indicam que grande parte dos registros é composta por textos curtos, embora existam mensagens consideravelmente mais extensas. O desvio-padrão de 44,16 caracteres reforça a presença de variações importantes no comprimento das publicações.

Para calcular essas medidas, os valores ausentes do campo de conteúdo foram tratados como textos vazios. Portanto, as estatísticas de comprimento incluem mensagens sem conteúdo textual, o que deve ser considerado na interpretação dos resultados.

A análise também identificou 192.616 mensagens com pelo menos um anexo. Esse valor é diferente do total de 219.186 anexos contabilizados na agregação por servidores, pois uma única mensagem pode conter mais de um arquivo. As contagens de URLs e emojis foram obtidas por regras de detecção textual e podem não abranger todas as formas de representação desses elementos.

Para verificar se o comprimento das mensagens varia entre os canais, analisamos os 15 canais com maior quantidade de registros. A Figura 6 apresenta o comprimento médio das mensagens em cada um deles.

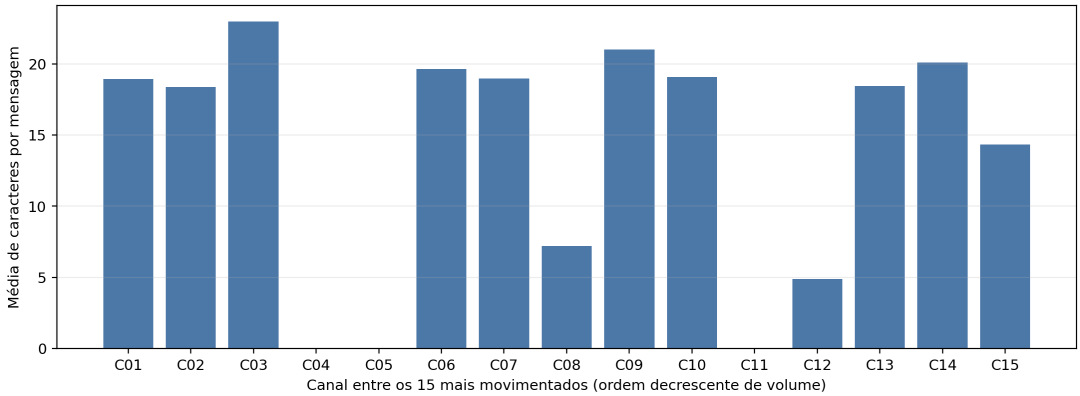


Figura 6. Comprimento médio das mensagens nos 15 canais de maior volume. Os rótulos C01–C15 representam as posições no ranking, sem expor identificadores dos canais.

Observamos diferenças entre os canais, inclusive entre aqueles com grande quantidade de mensagens. Em dois dos canais analisados, o comprimento médio dos textos é próximo de zero, indicando uma predominância de registros sem conteúdo textual ou com conteúdo muito reduzido.

Essa característica merece atenção nas próximas etapas, pois canais com muitas mensagens não necessariamente oferecem grandes quantidades de texto para a mineração temática. Entretanto, o comprimento reduzido, isoladamente, não permite concluir que esses canais sejam automatizados.

4.4. Análise preliminar de interações

Como exploração inicial das possibilidades de análise de redes, construímos uma representação de coparticipação entre usuários de um servidor. Foram selecionados os 30 nomes de usuários com maior frequência de mensagens, estabelecendo conexões entre pares que publicaram em um mesmo canal.

A rede resultante apresentou 30 nós, 406 arestas e densidade de 0,9333. Esse valor elevado indica que muitos dos usuários selecionados compartilharam pelo menos um canal de publicação dentro do critério adotado.

Entretanto, é importante distinguir **coparticipação de interação direta**. Uma conexão nessa rede significa apenas que dois nomes de usuários aparecem em um mesmo canal; ela não comprova que essas pessoas conversaram entre si, responderam às mensagens uma da outra ou mantêm algum vínculo social.

Por se tratar de um experimento limitado a um servidor e a um grupo reduzido de usuários, esses resultados são considerados preliminares. A análise posterior poderá investigar relações mais específicas, como menções e respostas, com critérios claros para a definição dos nós e das conexões.

4.5. Próximas etapas: processamento de linguagem natural

Os resultados exploratórios permitem compreender melhor a estrutura e as principais características da base, oferecendo suporte às próximas etapas da pesquisa. A continuidade

do trabalho será concentrada no Processamento de Linguagem Natural (PLN), com o objetivo de investigar os assuntos recorrentes nas comunidades analisadas.

Inicialmente, pretendemos preparar o conteúdo textual, considerando a identificação dos idiomas, o tratamento de URLs e menções, a presença de mensagens muito curtas e a influência de registros automatizados. Também será necessário estabelecer critérios para mensagens sem texto, de modo a adequar o conjunto às técnicas de mineração temática.

Após essa preparação, planejamos utilizar o **BERTopic** [1], uma abordagem de modelagem de tópicos que permite agrupar documentos com características semânticas semelhantes e identificar termos representativos de cada agrupamento.

A aplicação dessa técnica buscará identificar assuntos frequentes, observar diferenças temáticas entre servidores e investigar possíveis mudanças no conteúdo ao longo do tempo. Os agrupamentos obtidos deverão ser avaliados quanto à coerência, ao tamanho e à estabilidade, além de passar por interpretação qualitativa, preservando a privacidade dos participantes.

Essas análises ainda constituem etapas futuras. Assim, os resultados apresentados neste artigo se limitam à caracterização estatística, temporal e exploratória já realizada.

5. Conclusão

Este artigo documentou a preparação e a caracterização inicial de um conjunto extenso de mensagens de comunidades públicas do Discord. A etapa original de inventário identificou 15.886.553 mensagens em 2.051 arquivos Parquet, com esquema nominal de 23 colunas e sem duplicação de identificadores de mensagens. Na exportação analítica de 13.455.755 registros, foram descritos padrões temporais, concentração de atividade entre servidores e medidas de comprimento textual.

Os resultados preliminares evidenciam forte concentração: os cinco servidores com mais mensagens respondem por 67,7% da base consolidada. A predominância de textos curtos, a dispersão dos comprimentos e a ocorrência de mensagens sem texto reforçam a necessidade de limpeza criteriosa antes da análise temática. A documentação das etapas de preparação, por sua vez, busca assegurar a rastreabilidade e a reprodutibilidade das análises realizadas sobre a base consolidada.

A fase seguinte deverá consolidar os critérios de seleção, documentar o código de coleta e transformação e aplicar técnicas de PLN e modelagem de tópicos. Até que esses procedimentos sejam executados e avaliados, o estudo não apresenta conclusões sobre assuntos predominantes, sentimentos, toxicidade ou relações sociais causais entre os membros das comunidades.

Disponibilidade de Código

Os códigos de preparação, filtragem e análise exploratória desenvolvidos neste trabalho estão disponíveis em repositório público: `https://github.com/Rafael-Corgozinho/Minera-o-Discord`.

Referências

[1] Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*. `https://arxiv.org/abs/2203.05794`.